
Test loi de poisson

y : le nombre d'ALDs déclarées pour 100000 personnes dans le département.


hist(y,main="Histogram of observed data")

Histogram of observed data




plot(density(y), main="Density estimate of data")

Density estimate of data



plot(ecdf(y), main="Empirical cumulative distribution function")

Empirical cumulative distribution function



Le test du chi-square est défini pour l'hypothèse:

H0: les données suivent une distribution spécifiée

HA: les données ne suivent pas la distribution spécifiée

Pour le calcul de l'ajustement du *chi-square*, les données sont divisées en *k bins* et la statistique de test est définie de cette manière:


$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}$$

où O_i est la fréquence observée pour le bin i et E_i est la fréquence attendue pour le bin i.

La fréquence attendue est calculée par la fonction de distribution cumulative. Cette statistique est distribuée sous la forme d'une variable aléatoire χ^2 avec k-p-1 degrés de liberté (p) est le nombre de paramètres estimés par les données de l'échantillon). L'hypothèse selon laquelle les données proviennent d'une population avec la distribution spécifiée est acceptée si χ^2 est inférieur à la fonction du point de pourcentage du *chi-square* avec k-p-1 degrés de liberté et un niveau de signification de α . H0 est accepté car la valeur de pvalue est supérieure à un niveau de signification fixé au moins à 5%.

Dans l'environnement R, en cas de données de comptage, nous pouvons utiliserun fonction goodfit ()

Count data vs Poisson distribution



```
> # to automatically get the pvalue
> gf.summary = capture.output(summary(gf))[[5]]
> pvalue = unlist(strsplit(gf.summary, split = " "))
```

```
> pvalue = as.numeric(pvalue[length(pvalue)]); pvalue
[1] 0.7129117

> # to mannualy compute the pvalue
> chisq = sum( (gf$observed-gf$fitted)^2/gf$fitted)
> df = length(gf$observed)-1-1
> pvalue = pchisq(chisq,df); pvalue
[1] 0.2029661
```

Nous ne pouvons pas rejeter l'hypothèse nulle car la valeur de *p-value* est plutôt élevée, donc les données d'échantillon appartiennent probablement à une distribution de poisson avec paramètre $\lambda = \text{mean}(y)$

```
[1] 2.280301
> qqPlot(y, distribution = "pois", lambda = mean(yy), xlab = 'Theoretical
```

Quantiles', ylab = 'Empirical Quantiles', main = 'Q-Q plot Poisson')

Q-Q plot Poisson

> mean(y)

